

Wetenschappelijke onderzoeksmethoden — statistiek

Authors

Matt ter Steege
Matttersteege@gmail.com

Contents

1	Beschrijvende Statistiek	2
1.1	Het onderzoeksproces	2
1.2	Variabelen	2
1.3	Meetniveaus	2
1.4	Onderzoeksmethoden	3
1.5	Data	3
1.6	De standaardfout	3
1.7	Betrouwbaarheidsintervallen	3
2	T-testen	4

1 | Beschrijvende Statistiek

Statistiek is geen doel op zich maar een middel om vragen te beantwoorden. Onderzoek begint vrijwel altijd met nieuwsgierigheid: een observatie die wringt of opvalt. Om zulke vragen systematisch te beantwoorden zijn twee dingen nodig: data en een manier om die data te interpreteren. Statistiek vormt die brug.

Het onderzoeksproces

Onderzoek volgt doorgaans een vaste structuur:

1. **Observatie:** iets valt op en vraagt om verklaring.
2. **Theorie:** mogelijke verklaringen worden geformuleerd.
3. **Hypothese:** concrete, toetsbare voorspellingen.
4. **Dataverzameling:** meten van relevante variabelen.
5. **Analyse:** toetsen of data de hypothese ondersteunen.
6. **Conclusie:** theorie bevestigen, aanpassen of verwerpen.

Deze stappen hangen continu samen: data beïnvloeden theorieën en theorieën sturen nieuwe dataverzameling. Een hypothese moet empirisch toetsbaar zijn. Uitspraken die niet te meten zijn, vallen buiten de wetenschap. Een goede theorie (1) item genereert toetsbare voorspellingen, (2) kan weerlegd worden (falsificatie) en (3) verklaart bestaande en nieuwe data.

Normaliter zeg je met je hypothese wat er gaat gebeuren, wat je verwacht dat er gaat gebeuren. Echter kan het ook niet zo zijn. Het verwachte effect noem je H_1 , of je *alternative hypothesis*, als het drastisch de andere kant op gaat, dan is dat je H_0 . Hieronder is een visualisatie als de vraag “Is X beter dan Y”, je gaat er hier vanuit dat X beter is dan Y, maar dat moet je nu bewijzen. Je H_0 is hier dan, X is slechter óf gelijk aan Y, en je H_1 is X is beter dan Y!

Slechter	Gelijk	Beter
H_0		H_1

Variabelen

Variabelen zijn kenmerken die kunnen variëren:

- **Onafhankelijke variabele:** veronderstelde oorzaak.
- **Afhankelijke variabele:** verondersteld gevolg.

In niet-experimenteel onderzoek spreekt men vaak van *predictor* variabelen als vervanging van de onafhankelijke variabelen en *outcome* variabelen als vervanging van de afhankelijke variabelen.

Meetniveaus

Variabelen verschillen in hoe ze gemeten worden:

- **Categorisch:** Denk aan hondenrassen, fruitsoorten, etc.
 - Binair (twee categorieën), Er zijn 2 opties (bijvoorbeeld dood/levend, ja/nee)
 - Nominaal (geen volgorde), Is niet op een schaal (bijvoorbeeld rugnummers)
 - Ordinaal (wel volgorde, geen afstand), 1e, 2e en 3e worden, geeft niet aan hoe goed 1 tov 2 was
- **Continu:** Geeft een schaal aan, tov van elkaar
 - Interval (gelijke afstanden), bijvoorbeeld 1-5 sterren, 2 sterren is 2 keer beter dan 1 ster
 - Ratio (met absoluut nulpunt), bijvoorbeeld reactietijd

Onderzoeksmethoden

Bij **correlatieonderzoek** observeer je variabelen zonder in te grijpen. Voordeel: realistisch beeld. Nadeel: geen causale conclusies mogelijk, o.a. door:

- onduidelijke volgorde (wat komt eerst?),
- derde variabelen (confounds).

Bij **Experimenteel onderzoek** manipuleer je een variabele en meet je het effect. Dit maakt causale uitspraken mogelijk, mits:

- oorzaak voorafgaat aan gevolg,
- andere verklaringen uitgesloten worden.

Onderzoek op subjects kan je op twee manieren inrichten:

- **Between-subjects**: verschillende groepen per conditie.
- **Within-subjects**: dezelfde deelnemers in alle condities.

Within-subjects designs hebben vaak meer statistische power, omdat individuele verschillen constant blijven.

Data

In data zijn twee soorten variatie:

- **Systematische variatie**: veroorzaakt door de manipulatie.
- **Aselecte variatie**: ruis door toevallige factoren.

Statistiek probeert deze twee uit elkaar te halen. Random toewijzen van deelnemers aan condities voorkomt systematische vertekening en verdeelt storende variabelen gelijkmatig.

Een histogram toont hoe vaak waarden voorkomen. Belangrijke vormen:

- **Normaalverdeling**: symmetrisch, klokvormig.
- **Scheefheid (skew)**: asymmetrie in verdeling.
- **Kurtosis**: mate van piek en staarten.

Drie maten beschrijven het centrum:

- **Gemiddelde** (mean)
- **Mediaan** (middelste waarde)
- **Modus** (meest voorkomende waarde)

De standaardfout

De standaardfout pakt dat probleem direct aan. In plaats van te kijken naar spreiding binnen één steekproef (standaarddeviatie), kijk je naar spreiding tussen steekproefgemiddelden. Dus: hoe stabiel is jouw gemiddelde als je het experiment opnieuw zou doen?

- kleine standaardfout → steekproeven lijken op elkaar → je schatting is betrouwbaar
- grote standaardfout → veel variatie → je schatting is instabiel

Dus als die standaardfout groot is, dan kan alles net zo goed toeval zijn.

Betrouwbaarheidsintervallen

Omdat één getal (het gemiddelde) eigenlijk te mager is, trek je er grenzen omheen: een interval. Dat interval geeft een bereik waarbinnen het echte populatiegemiddelde waarschijnlijk ligt.

Voor een 95% betrouwbaarheidsinterval geldt:

$$\text{ondergrens} = \bar{X} - 1.96 \cdot SE$$

$$\text{bovengrens} = \bar{X} + 1.96 \cdot SE$$

Wat hier belangrijk is de interpretatie. Het betekent niet dat de kans 95% is dat het echte gemiddelde in dit specifieke interval ligt. Het betekent dat als je dit proces eindeloos herhaalt, 95% van die intervallen het echte gemiddelde bevat. Een smalle interval betekent dat je dicht op de waarheid zit.

2 | T-testen

Een t-test wordt gebruikt om te toetsen of twee gemiddelden van elkaar verschillen. De hypothesen worden als volgt geformuleerd:

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{vs.} \quad H_a : \mu_1 - \mu_2 \neq 0$$

Onafhankelijke t-test

De onafhankelijke t-test wordt toegepast bij twee afzonderlijke groepen. Het verschil tussen de groepsgemiddelden wordt beoordeeld met:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\text{standaardfout}}$$

De vrijheidsgraden worden berekend als:

$$df = n_1 + n_2 - 2$$

De uitkomst wordt geïnterpreteerd via de t-waarde en de bijbehorende p-waarde. Indien $p < \alpha$, wordt de nulhypothese verworpen.

Belangrijke assumpties:

- Onafhankelijke observaties
- Normaliteit van de verdeling
- Homogeniteit van varianties

Bij schending van gelijke varianties kan Welch's t-test worden gebruikt.

Afhankelijke (gepaarde) t-test

De afhankelijke t-test wordt gebruikt bij herhaalde metingen binnen dezelfde groep. Hierbij wordt gewerkt met verschilscore:

$$D_i = X_{1i} - X_{2i}$$

De hypothese is:

$$H_0 : \mu_D = 0$$

De t-waarde wordt berekend als:

$$t = \frac{\bar{D}}{\text{standaardfout van } D}$$

De normaliteitsaannname geldt voor de verdeling van de verschillen D , niet voor de oorspronkelijke metingen.

Bij schending van de normaliteitsaannname kan de Wilcoxon signed-rank test worden toegepast.

Effectgrootte

Naast significantie wordt de effectgrootte gerapporteerd, bijvoorbeeld met Pearson's r :

$$r = 0.1 \text{ (klein)}, \quad 0.3 \text{ (gemiddeld)}, \quad 0.5 \text{ (groot)}$$

Rapportage

Resultaten worden gerapporteerd in de vorm:

$$t(df) = \text{waarde}, \quad p = \text{waarde}$$

Interpretatie

Een t-test toetst of een verschil tussen gemiddelden significant afwijkt van nul. In regressietermen komt dit overeen met het toetsen van een regressiecoëfficiënt:

$$b_1 = 0$$

De conclusie is gebaseerd op de p-waarde en de grootte van het effect.

Formuleblad (kort)

Gegeven: $X = \{4, 6, 8\}$, $n = 3$

Gemiddelde

Balanspunt van de data.

$$\bar{X} = \frac{\sum X_i}{n} = \frac{18}{3} = 6$$

Mediaan

Middelste waarde (gesorteerd), robuust voor uitschieters.

$$\text{Mediaan} = 6$$

Modus

De modus is de waarde die het meest voorkomt, in een frequency distribution grafiek is het de hoogste piek.

Deviaties

Afstand tot het gemiddelde van elk getal (som = 0).

$$X_i - \bar{X} : -2, 0, 2$$

Sum of Squares (SS)

Kwadrateert afwijkingen (geen opheffing).

$$SS = \sum (X_i - \bar{X})^2 = 4 + 0 + 4 = 8$$

Variantie

Gemiddelde spreiding (met $n - 1$ correctie).

$$s^2 = \frac{SS}{n - 1} = \frac{8}{2} = 4$$

Standaarddeviatie

Terug naar originele schaal.

$$s = \sqrt{4} = 2$$

Z-score

Aantal standaarddeviaties van het gemiddelde.

$$z = \frac{X_i - \bar{X}}{s} : -1, 0, 1$$